

Construcción de un modelo para predecir la mortalidad en pacientes en diálisis renal

Autor

Lic. Ezequiel Scordamaglia

Director del trabajo

Esp. Ing. Trinidad Monreal

Este plan de trabajo ha sido realizado en el marco de la asignatura Gestión de Proyectos entre octubre y noviembre de 2023.

Tabla de contenido

1. Breve resumen del trabajo realizado hasta la fecha	3
1.1 Descripción breve del proyecto	3
1.2 Avances hasta la fecha	4
1.3 Tareas faltantes	8
2. Avance en las tareas	9
3. Cumplimiento de los requerimientos	11
4. Gestión de riesgos	13

IMPORTANTE: No borrar las consignas en cada una de las cuatro secciones de este documento, de forma tal que el jurado tenga claro qué es lo solicitado en cada caso, así como el significado de los símbolos y colores utilizados.

Revisión	Cambios realizados	Fecha
1.0	Creación del documento	15/03/2024
1.1	Actualización de las métricas del mejor modelo hasta la fecha	21/03/2024

1. Breve resumen del trabajo realizado hasta la fecha

Elabore un detalle del estado del proyecto a la fecha. **Utilicé como mínimo dos páginas completas y como máximo tres páginas.** Explique muy brevemente en qué consiste su Trabajo Final, **aunque esa información esté más detallada en el Plan de Trabajo al cual su Jurado también tiene acceso.** Incluya imágenes y tablas según considere apropiado. **Indique con claridad por qué estima que podrá completar todos los faltantes (o al menos la gran mayoría) antes del inicio del Taller de Trabajo Final.**

1.1 Descripción breve del proyecto

La diálisis renal es un tratamiento que sustituye la función renal cuando ésta se pierde debido a enfermedades renales crónicas, insuficiencia renal aguda u otros problemas de salud que afectan la función renal. Es un proceso artificial que elimina desechos y exceso de líquido de la sangre.

La hemodiálisis (HD) y la diálisis peritoneal (DP) son dos métodos de diálisis utilizados para tratar la insuficiencia renal. La hemodiálisis implica el paso de la sangre a través de un filtro fuera del cuerpo, generalmente una máquina de diálisis, donde se eliminan los desechos y el exceso de líquido antes de devolver la sangre al cuerpo. Por otro lado, en la diálisis peritoneal, se utiliza el revestimiento abdominal (peritoneo) como un filtro natural. Se introduce un líquido de diálisis a través de un catéter en la cavidad abdominal, donde absorbe los desechos y el exceso de líquido, luego se drena fuera del cuerpo. Ambos métodos tienen sus propias ventajas y consideraciones, y la elección entre ellos depende de las necesidades y circunstancias del paciente.

El objetivo principal de este trabajo es desarrollar toda la arquitectura necesaria para que una organización médica dedicada a la diálisis renal pueda predecir el riesgo de mortalidad de sus pacientes haciendo uso de técnicas de inteligencia artificial (IA). Esto le permitirá al personal médico adaptar los tratamientos y la medicación prescrita para mejorar la calidad de vida de los pacientes y, en última instancia, salvar vidas.

El proyecto consta del desarrollo de un modelo predictivo que utilice técnicas de IA y la configuración de una plataforma de gestión de modelos. Por otro lado se desarrollará una interfaz por servicio web y un proceso automático que solicite predicciones y se las presente al usuario en forma de reporte. En la figura 1 se muestra la arquitectura propuesta.

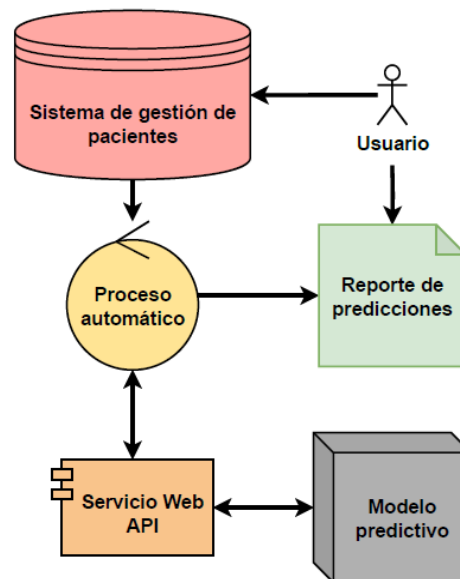


Figura 1: Arquitectura del sistema.

1.2 Avances hasta la fecha

En la primera etapa se realizó el plan de proyecto, donde se detalla el alcance, los objetivos, los requerimientos y la gestión de riesgos. Luego se realizó una exploración de trabajos que tratan la temática de la predicción de mortalidad en diálisis renal para reunir toda aquella información que pueda ser relevante para el desarrollo de este trabajo. Se han encontrado varias publicaciones que abordan el tema desde diferentes puntos de vista y utilizan distintas estrategias para lograr la predicción, lo que sirvió de punto de partida para este desarrollo.

Hasta el momento se realizaron con éxito las tareas indicadas en la figura 2:

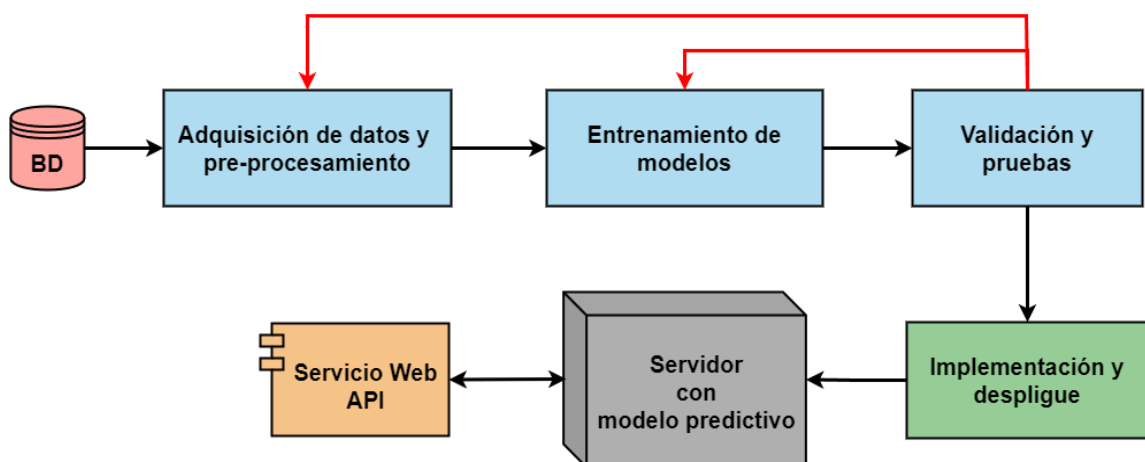


Figura 2: Etapas realizadas con éxito.

En primer lugar, se realizó una consulta con un médico de la organización dedicada a la diálisis renal, con quien definimos qué variables médicas tienen más influencia en la mortalidad de los pacientes. Se seleccionaron 40 variables a utilizar, entre las cuales se encuentran la edad, el peso, la altura, el sexo, la cantidad de días en diálisis, el acceso vascular y algunas variables del último examen de laboratorio realizado. Se cuenta con información médica de aproximadamente 14.000 pacientes, los cuales a su vez tienen laboratorios clínicos todos los meses. Se definió que sólo se tendrán en cuenta para el desarrollo de este modelo a los pacientes con más de 90 días en tratamiento del tipo hemodiálisis, ya que es el tratamiento más común y antes de los 90 días suele haber mucha mortalidad.

Con esta información se realizaron diferentes conjuntos de datos (datasets) con distintas estrategias para entrenar los modelos de IA. Como primera estrategia se incluyó en el dataset a todo paciente que lleve más de 90 días en tratamiento HD, sin importar si se encuentra fallecido o no fallecido. Cada paciente incluyó datos del último examen de laboratorio que tenía registrado. Este dataset quedó conformado con 14.000 pacientes, de los cuales el 68% no había fallecido.

La segunda estrategia incluyó a todo paciente con más de 90 días en tratamiento de hemodiálisis y que haya fallecido entre los años 2013 y 2023 (ya que los pacientes fallecidos antes de 2013 tenían muchos datos faltantes). A ese grupo se le sumaron pacientes que no habían fallecido, por lo que se seleccionó a aquellos que estaban activos el último día del año de 2020, 2021 y 2022 (existiendo la posibilidad de que se repitan los pacientes, pero con estado de salud y datos distintos). El dataset quedó conformado por 14.100 pacientes, 5800 pacientes fallecidos y 8300 pacientes no fallecidos, lo que deja un desequilibrio de 58/41 en favor de los no fallecidos.

En ambas estrategias se trabajó con las mismas 40 variables por lo que el pre-procesamiento de los datos fue similar. De cada dataset generado se utilizó el 75% de los datos para el entrenamiento y el 25% restante para la prueba. Se aplicó un bloque de corrección de inconsistencias en los valores recibidos, discretización de algunas variables e imputación de valores nulos con la técnica de imputación multivariada por ecuaciones encadenadas (MICE). Se codificaron las variables categóricas utilizando la técnica codificación uno a uno (One-hot), obteniendo un dataset numérico completo con aproximadamente 100 variables.

Se intentó aplicar técnicas de balanceo del dataset, como son sobremuestreo de minorías sintéticas (SMOTE) y submuestreo aleatorio, para intentar equilibrar la situación, pero no se obtuvieron buenos resultados. Como segunda opción, se están ajustando parámetros de los modelos para darle más peso a la clase minoritaria durante el entrenamiento.

Con las distintas versiones del dataset se entrenaron distintos modelos de aprendizaje automático (Machine Learning) y aprendizaje profundo (Deep Learning) y se compararon sus resultados con distintas métricas como el accuracy, precision, recall, F1 score y AUC.

De los modelos de Machine Learning entrenados se eligió el de Bosque Aleatorio (Random Forest), que fue el que obtuvo los mejores resultados en los distintos entrenamientos. Y por parte del Deep

Learning, se diseñó una red neuronal de 3 capas ocultas con 200, 100 y 50 nodos respectivamente, con función de activación ReLU y capas de dropout entre cada capa de neuronas.

Para la validación de los modelos se generó un dataset nuevo con los pacientes que llevan más de 90 días en tratamiento de hemodiálisis con su estado al final del mes de enero de 2024, incluyendo fallecidos y no fallecidos.

Hasta el momento, los mejores resultados se obtuvieron con la segunda estrategia de dataset y con el modelo de red neuronal.

A continuación se muestran las métricas resultantes del desempeño del modelo.

Resultados sobre datos de prueba:

- Accuracy: 0.89
- F1 Score: 0.88
- Presicion: 0.81
- Recall: 0.95
- AUC: 0.97

Resultados sobre datos de validación:

- Accuracy: 0.78
- F1 Score: 0.06
- Presicion: 0.03
- Recall: 0.73
- AUC: 0.80

En las figuras 3 y 4 se puede observar las matrices de confusión con los datos de prueba y de validación respectivamente.

Si bien los resultados de las métricas en validación no son tan altos como en la prueba, la detección temprana del 73% de los casos que tienen alto riesgo (recall en validación de 0.73) representa una información muy importante para el personal médico que atiende a dichos pacientes y les daría la oportunidad de ajustar los tratamientos para mejorar su estado de salud.




Figura 3: Matriz de confusión con datos de prueba.




Figura 4: Matriz de confusión con datos de validación.

Aunque se continúa trabajando en el pre-procesamiento de los datos para aprovechar al máximo las relaciones entre ellos y en el entrenamiento de modelos, se avanzó de todas formas con las siguientes tareas programadas. Por tal motivo se configuró una plataforma de integración continua llamada Jenkins, con la cual se desplegó el modelo en un servidor. Se eligió dicha plataforma porque ya se

utilizaba en la organización y se pudo adaptar para instalar los modelos predictivos en los distintos ambientes.

También se construyó un prototipo de Servicio Web (API) que tiene dos métodos: el primero recibe un archivo .CSV para realizar las predicciones masivamente, y el segundo permite enviar un valor para cada una de las 40 variables para realizar una predicción individual.

1.3 Tareas faltantes

Se estima que el proyecto podrá ser completado dentro del plazo establecido, dado que ya se cuenta con algunos modelos entrenados y desplegados en un servidor, y también se cuenta con una API para realizar consultas al modelo.

Las actividades pendientes incluyen terminar de entrenar al modelo y desplegar la última versión en el servidor, adaptar la API para que funcione correctamente con el modelo desplegado y desarrollar una aplicación que se ejecute cada cierto tiempo, recupere los pacientes activos de la base de datos y solicite las predicciones al modelo. Por otra parte, se elaborará un documento sobre el modelo predictivo que detalle las variables utilizadas, la arquitectura de modelo seleccionada y las métricas logradas. También se elaborará un documento que describa los métodos de la API para realizar predicciones sobre el modelo.

2. Avance en las tareas

a) Indicar a continuación para cada una de las tareas su estado de situación según su criterio, utilizando verde si considera que es satisfactorio, amarillo si considera que es insatisfactorio por sobrecostos y/o demoras, y rojo si lo considera muy insatisfactorio por sobrecostos y/o demoras.

Si a la fecha de completar este informe no está previsto que la tarea haya comenzado entonces deje la celda correspondiente en blanco, sin pintarla con ningún color.

En subcelda inferior izquierda colocar:

- ** si los recursos u horas utilizadas fueron o están siendo muy inferior a lo planificado.
- * si los recursos u horas utilizadas fueron o están siendo inferior a lo planificado.
- \$ si los recursos u horas utilizadas fueron o están siendo de acuerdo a lo planificado.
- \$\$ si los recursos u horas utilizadas fueron o están siendo superior a lo planificado.
- \$\$\$ si los recursos u horas utilizadas fueron o están siendo muy superior a lo planificado.

En subcelda inferior derecha colocar:

- -- si la tarea se ejecutó o se está ejecutando mucho más rápido de lo previsto
- - si la tarea se ejecutó o se está ejecutando más rápido de lo previsto
- = si la tarea se ejecutó o se está ejecutando en el tiempo previsto.
- + si la tarea se ejecutó o se está ejecutando con demoras.
- ++ si la tarea se ejecutó o se está ejecutando con demoras muy significativas.

IMPORTANTE: Indicar con borde grueso las tareas que forman parte del camino crítico

1.1. Investigación sobre variables médicas que tienen influencia en la mortalidad	1.2. Extracción de datos médicos de la base de datos	1.3. Procesamiento de datos médicos	1.4. Entrenamiento de modelos de <i>machine learning</i>
\$	=	\$\$	+
1.5. Entrenamiento de modelos de <i>deep learning</i>	1.6. Evaluación de métricas de los modelos	1.7. Selección de los modelos candidatos	1.8. Ajuste fino de los modelos seleccionados
\$\$	+	\$	+
2.1. Diseño de la interfaz	2.2. Implementación de la interfaz	2.3. Pruebas sobre la interfaz para obtener predicciones	3.1. Investigación de plataformas de gestión de modelos disponibles
\$	=	\$	=
			**
			--

3.2. Instalación de plataforma de gestión seleccionada		3.3. Configuración de ambientes para despliegue de modelos		4.1. Diseño del proceso que solicita predicciones automáticamente		4.2. Desarrollo del proceso que solicita predicciones automáticamente	
**	--	\$	--				
4.3. Pruebas de automatización de llamadas al modelo		5.1. Documentación del servicio web		5.2. Documentación del modelo predictivo		5.3. Documentación de informe de avance	
5.4. Informe final del proyecto							

3. Cumplimiento de los requerimientos

a) Indicar a continuación para cada uno de los requerimientos el estado de situación según su criterio, utilizando verde si considera que ya se ha cumplido, amarillo si considera que aún no se ha cumplido pero se podrá cumplir, y rojo si considera que aún no se ha cumplido y tiene dudas si se podrá cumplir.

Si considera que es necesario modificar los requerimientos respecto a los indicados en la planificación inicial entonces incluya acá los requerimientos actualizados, **marcando en negrita** aquellos que son nuevos o se han modificado.

Req #1.1: La plataforma de gestión de modelos deberá permitir desplegar modelos en diversos ambientes.
Req #1.2: La interfaz por servicio web deberá recibir datos médicos de uno o varios pacientes y devolver las predicciones asociadas a ellos
Req #1.3: El modelo predictivo deberá tener una precisión de al menos un 75%
Req #1.4: El proceso que solicita predicciones y genera el reporte al usuario deberá poder ejecutarse automáticamente cada cierto período de tiempo
Req #1.5: El reporte de predicciones que le llegue al usuario final deberá tener un formato claro y comprensible.
Req #1.6: Se utilizará GIT como repositorio para el control de versión de código.
Req #2.1: Durante el entrenamiento del modelo se deberá resguardar la confidencialidad de los datos de los pacientes.
Req #3.1: Redactar una memoria técnica con la información del proyecto.

Req #3.2: La documentación de la interfaz por servicio web deberá incluir la lista de métodos disponibles con su detalle.

Req #3.3: La documentación del modelo predictivo incluirá información sobre el origen de los datos utilizados para el entrenamiento, las características que se usaron, el detalle del modelo seleccionado y la información que haya sobre la explicabilidad del modelo

4. Gestión de riesgos

a) Indicar a continuación para cada uno de los riesgos el estado de situación según su criterio, utilizando verde si considera que el riesgo ya no se manifestará o es muy improbable que se manifieste, amarillo si considera que es posible que es improbable que el riesgo se manifieste o si se manifiesta estima que será fácilmente controlado, y rojo si considera que es muy probable que el riesgo se manifieste y que no pueda ser controlado fácilmente.

Si considera que es necesario modificar los riesgos respecto a los presentados en la planificación inicial entonces incluya acá los riesgos actualizados, **marcando en negrita** aquellos que son nuevos o se han modificado, e indicando para ellos los valores de S, O y RPN, junto con su respectiva justificación.

Riesgo #1: No disponer de un conjunto de datos adecuado para el entrenamiento del modelo.

Riesgo #2: No lograr que el modelo entrenado realice predicciones correctas.

Riesgo #3: Falta de colaboración por parte de los médicos interesados para la selección de variables que tengan relación con la mortalidad.

Riesgo #4: Pérdida o daño en los archivos del proyecto.

Riesgo #5: No finalizar las tareas según las fechas planificadas.